Определение стоимости автомобилей

В нашем распоряжении исторические данные сервиса по продаже автомобилей с пробегом: технические характеристики, комплектации и цены автомобилей.
Сервис разрабатывает приложение для привлечения новых клиентов. В нём можно быстро узнать рыночную стоимость своего автомобиля.

Наша задача построить модель, для определения стоимости автомобиля, учитывая следующие критерии:

- качество предсказания;
- скорость предсказания;
- время обучения.

In [1]
```
# устанавливаем библиотеки
!pip install lightgbm
```

```
Requirement already satisfied: lightgbm in e:\anaconda3\envs\ds_practicum\lib\sit
e-packages (3.3.5)
Requirement already satisfied: scikit-learn!=0.22.0 in e:\anaconda3\envs\ds_pract
icum\lib\site-packages (from lightgbm) (0.24.1)
Requirement already satisfied: scipy in e:\anaconda3\envs\ds_practicum\lib\site-p
ackages (from lightgbm) (1.8.0)
Requirement already satisfied: numpy in e:\anaconda3\envs\ds_practicum\lib\site-p
ackages (from lightgbm) (1.20.1)
Requirement already satisfied: wheel in e:\anaconda3\envs\ds_practicum\lib\site-p
ackages (from lightgbm) (0.38.4)
Requirement already satisfied: joblib>=0.11 in e:\anaconda3\envs\ds_practicum\lib
\site-packages (from scikit-learn!=0.22.0->lightgbm) (1.2.0)
Requirement already satisfied: threadpoolctl>=2.0.0 in e:\anaconda3\envs\ds_pract
icum\lib\site-packages (from scikit-learn!=0.22.0->lightgbm) (3.1.0)
```

In [2]
```
# импортируем библиотеки
import os
import time
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.preprocessing import OrdinalEncoder
from sklearn.ensemble import RandomForestRegressor
from lightgbm import LGBMRegressor
from catboost import CatBoostRegressor
from sklearn.metrics import mean_squared_error
```

Подготовка данных

Обзор данных

Откроим файл с данными, изучим общую информацию.

In [3]
```
pth1 = '/datasets/autos.csv'
pth2 = 'https://restricted/datasets/autos.csv'

if os.path.exists(pth1):
    data = pd.read_csv(pth1)
#elif os.path.exists(pth2):
#    data = pd.read_csv(pth2)
else:
    try:
        data = pd.read_csv(pth2)
    except:
        print('Something is wrong, datasets not found!!!')
```

In [4]
```
# Выведем общую инф о df
def df_info(df):
    display(df.head())
    display(df.info())
    display(df.describe())
    print("Количество дубликатов:", df.duplicated().sum())

def nan_info(df):
    zero_val = (df == 0).astype(int).sum(axis=0)
    zero_val_percent =  round(zero_val / len(df) * 100, 2)
    mis_val = df.isnull().sum()
    mis_val_percent = round(mis_val / len(df) * 100, 2)

    info_table = pd.concat([zero_val, zero_val_percent, mis_val, mis_val_percent
    info_table = info_table.rename(
            columns={0: 'Нулевые значения', 1: '% значений', 2: 'Кол-во пропуско
    display(info_table)
    print("Данные представлены в", df.shape[1], "столбцах и", df.shape[0], "стро
    print("В", info_table[info_table.iloc[:, 2] != 0].shape[0], "столбцах имеютс
```

In [5]
```
df_info(data)
nan_info(data)
```

	DateCrawled	Price	VehicleType	RegistrationYear	Gearbox	Power	Model	Kilomete
0	2016-03-24 11:52:17	480	NaN	1993	manual	0	golf	150000
1	2016-03-24 10:58:45	18300	coupe	2011	manual	190	NaN	125000
2	2016-03-14 12:52:21	9800	suv	2004	auto	163	grand	125000
3	2016-03-17 16:54:04	1500	small	2001	manual	75	golf	150000
4	2016-03-31 17:25:20	3600	small	2008	manual	69	fabia	90000

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 354369 entries, 0 to 354368
Data columns (total 16 columns):
 #   Column             Non-Null Count   Dtype
---  ------             --------------   -----
 0   DateCrawled        354369 non-null  object
 1   Price              354369 non-null  int64
 2   VehicleType        316879 non-null  object
 3   RegistrationYear   354369 non-null  int64
 4   Gearbox            334536 non-null  object
 5   Power              354369 non-null  int64
 6   Model              334664 non-null  object
 7   Kilometer          354369 non-null  int64
 8   RegistrationMonth  354369 non-null  int64
 9   FuelType           321474 non-null  object
 10  Brand              354369 non-null  object
 11  Repaired           283215 non-null  object
 12  DateCreated        354369 non-null  object
 13  NumberOfPictures   354369 non-null  int64
 14  PostalCode         354369 non-null  int64
 15  LastSeen           354369 non-null  object
dtypes: int64(7), object(9)
memory usage: 43.3+ MB
None
```

	Price	RegistrationYear	Power	Kilometer	RegistrationMonth
count	354369.000000	354369.000000	354369.000000	354369.000000	354369.000000
mean	4416.656776	2004.234448	110.094337	128211.172535	5.714645
std	4514.158514	90.227958	189.850405	37905.341530	3.726421
min	0.000000	1000.000000	0.000000	5000.000000	0.000000
25%	1050.000000	1999.000000	69.000000	125000.000000	3.000000
50%	2700.000000	2003.000000	105.000000	150000.000000	6.000000
75%	6400.000000	2008.000000	143.000000	150000.000000	9.000000
max	20000.000000	9999.000000	20000.000000	150000.000000	12.000000

```
Количество дубликатов: 4
```

	Нулевые значения	% значений	Кол-во пропусков	% пропусков
DateCrawled	0	0.00	0	0.00
Price	10772	3.04	0	0.00
VehicleType	0	0.00	37490	10.58
RegistrationYear	0	0.00	0	0.00
Gearbox	0	0.00	19833	5.60
Power	40225	11.35	0	0.00
Model	0	0.00	19705	5.56
Kilometer	0	0.00	0	0.00
RegistrationMonth	37352	10.54	0	0.00
FuelType	0	0.00	32895	9.28
Brand	0	0.00	0	0.00
Repaired	0	0.00	71154	20.08
DateCreated	0	0.00	0	0.00
NumberOfPictures	354369	100.00	0	0.00
PostalCode	0	0.00	0	0.00
LastSeen	0	0.00	0	0.00

Данные представлены в 16 столбцах и 354369 строках

Данные представлены следующими признаками

- `DateCrawled` — дата скачивания анкеты из базы
- `VehicleType` — тип автомобильного кузова
- `RegistrationYear` — год регистрации автомобиля
- `Gearbox` — тип коробки передач
- `Power` — мощность (л. с.)
- `Model` — модель автомобиля
- `Kilometer` — пробег (км)
- `RegistrationMonth` — месяц регистрации автомобиля
- `FuelType` — тип топлива
- `Brand` — марка автомобиля
- `Repaired` — была машина в ремонте или нет
- `DateCreated` — дата создания анкеты
- `NumberOfPictures` — количество фотографий автомобиля
- `PostalCode` — почтовый индекс владельца анкеты (пользователя)
- `LastSeen` — дата последней активности пользователя

Целевой признак

- `Price` — цена (евро)

В данных присутствуют пропуски, нулевые значения и аномалии - требуется предобработка данных.

Предобработка данных

Дубликаты

В данных присутствуют явные дубликаты, удалим их

In [6]
```
data = data.drop_duplicates().reset_index(drop=True)
```

Пропуски

В столбце `Model` — модель автомобиля, достоверно узнать модель авто не представляется, удалим эти данные

In [7]
```
data.dropna(subset=['Model'], inplace=True)
```

В столбце `VehicleType` — тип автомобильного кузова, присутствуют пропуски (более 10%). Так как достоверно узнать тип кузова невозможно заменим на 'unknown'

In [8]
```
data.VehicleType = data.VehicleType.fillna('unknown')
```

В столбце `Gearbox` — тип коробки передач и `FuelType` — тип топлива, пропуски заменим наиболее часто встречаемым для пары `Brand` - `Model`

In [9]
```
def fill_with_mode(col):
    data[col] = data.groupby(['Brand', 'Model'])[col].apply( lambda x: x.fillna(
```

In [10]
```
fill_with_mode('Gearbox')
fill_with_mode('FuelType')
```

Пропуски в столбце `Repaired` — была машина в ремонте или нет, заполним исходя из того что отсутствие данных свидетельствует о том, что пользователь явно не указывал о ремонте машины т.к. его (ремонта) не было. Возможен технический сбой

In [11]
```
data.Repaired = data.Repaired.fillna('no')
```

Аномалии

К явным выбросам отнесем следующее:

- В `Price` — цена, наблюдается необчно низкая (нулевая) и достаточно высокая стоимость авто;

- В `Power` — мощность (л.с.), наблюдается необчно низкая (нулевая) и достаточно высокая мощность;
- В `RegistrationYear` — год регистрации автомобиля, смущает минимальное значение (1000) и максимальное (9999).

Посмотрим на `Price`

In [12]
```
data.Price.plot(kind="hist",
                      title='Распределение по признаку Price',
                      alpha=0.5,
                      bins=100)
plt.xlabel('Цена, евро')
plt.ylabel('Частота')
plt.show()
plt.figure(figsize=(10, 5))
ax=sns.boxplot(x = data.Price)
ax.set()
plt.xlabel('Цена, евро')
plt.title('Распределение по признаку Price')
plt.show()
```

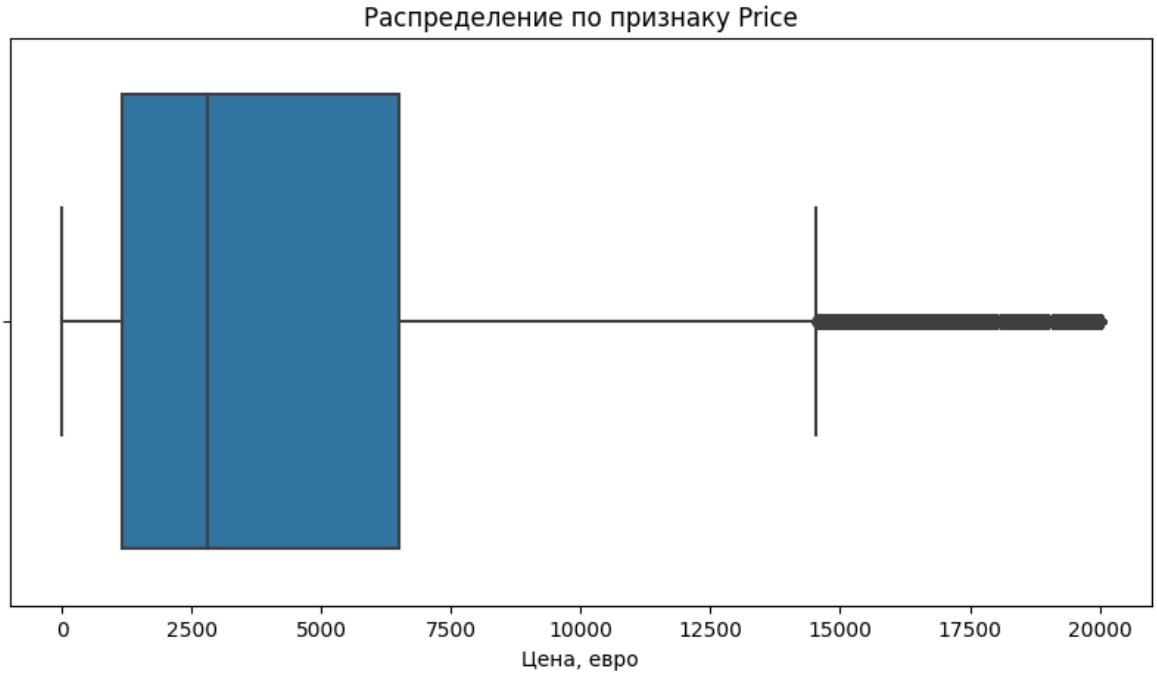

Отсеим выбросы с очень низкой (до 200) и очень высокой (более 14800) ценой

In [13]
```
data = data[(data['Price']>=200) & (data['Price']<=14800)]
```

Посмотрим на `Power`

In [14]
```
data[(data['Power']>=40) & (data['Power']<=300)].Power.plot(kind="hist",
                      title='Распределение по признаку Power',
                      alpha=0.5,
                      bins=100)
plt.xlabel('мощность (л.с.)')
plt.ylabel('Частота')
plt.show()
plt.figure(figsize=(10, 5))
ax=sns.boxplot(x = data[(data['Power']>=40) & (data['Power']<=300)].Power)
ax.set()
plt.xlabel('мощность (л.с.)')
plt.title('Распределение по признаку Power')
plt.show()
```

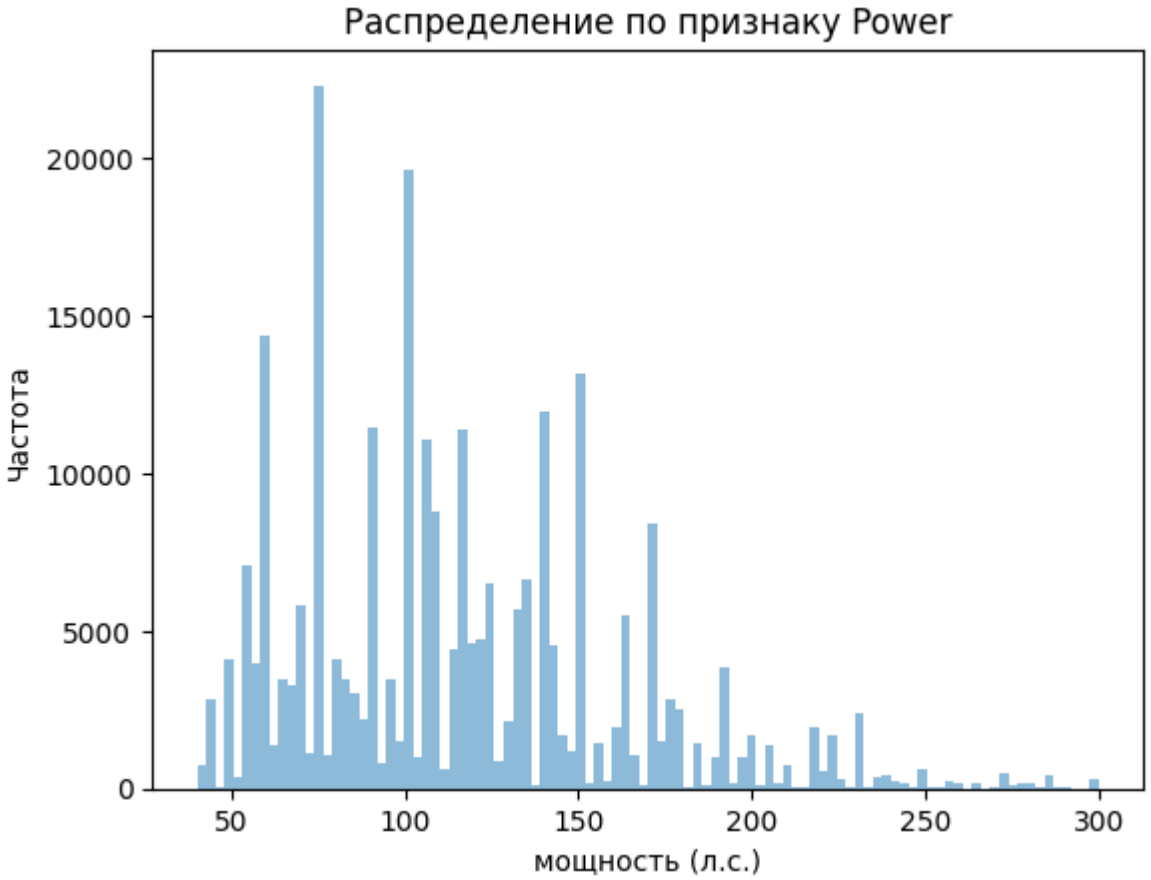

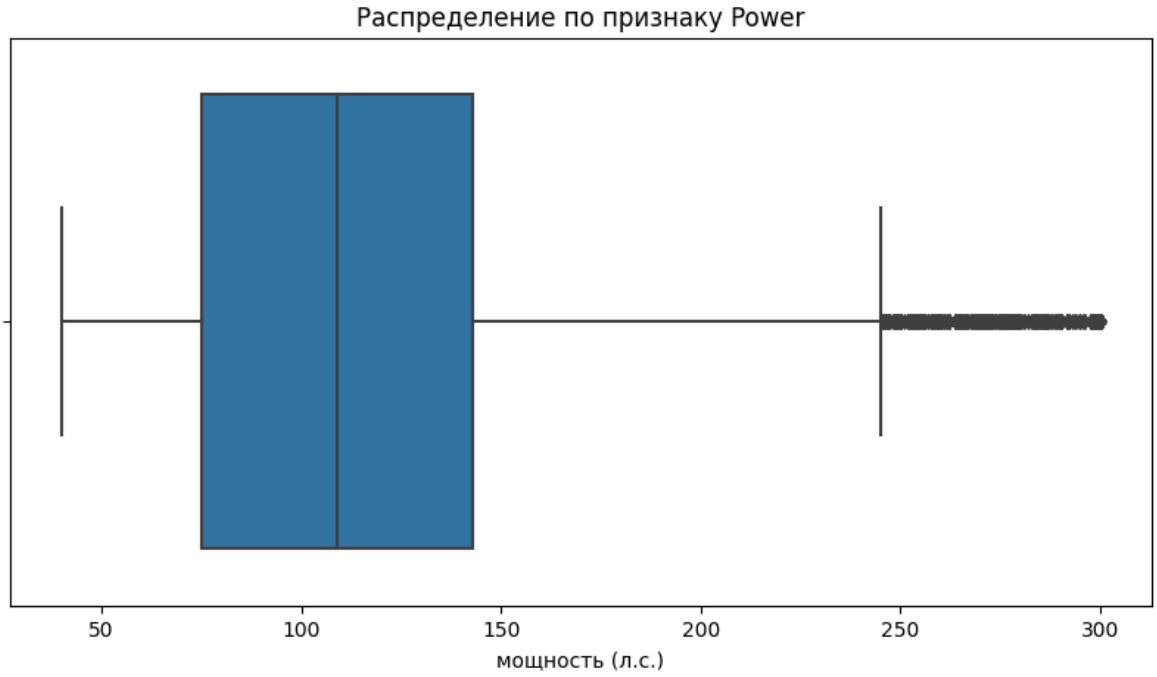

Отсеим выбросы с очень низкой (до 40) и очень высокой (более 300) мощностью

In [15]
```
data = data[(data['Power']>=40) & (data['Power']<=300)]
```

Посмотрим на `RegistrationYear`

В данных присутствует признак `DateCreated` — дата создания анкеты, отсеим максимальные значения исходя из соображения что год регистрации авто не может быть больше чем дата создания анкеты в сервисе, а минимальные исходя из даты производства первого серийного автомобиля - 1895г

In [16]
```
data['DateCreated'] = pd.to_datetime(data['DateCreated'], format='%Y-%m-%d')

data = data[(data['RegistrationYear']>=1895) & (data['RegistrationYear']<=data['
```

Уберем неинформативные признаки:

- `DateCrawled` — дата скачивания анкеты из базы
- `RegistrationMonth` — месяц регистрации автомобиля
- `DateCreated` — дата создания анкеты
- `NumberOfPictures` — количество фотографий автомобиля
- `PostalCode` — почтовый индекс владельца анкеты (пользователя)
- `LastSeen` — дата последней активности пользователя

В связи с тем, что они никоим образом не влияют на итоговую стоимость автомобиля и носят информационный характер для сервиса

In [17]
```
data.drop(['DateCrawled', 'RegistrationMonth', 'DateCreated', 'NumberOfPictures'
```

In [18]
```
data.reset_index(drop=True, inplace=True)
```

Посмотрим на итоговые данные

In [19]
```
display(data.describe())
nan_info(data)
```

	Price	RegistrationYear	Power	Kilometer
count	263219.000000	263219.000000	263219.000000	263219.000000
mean	4198.163438	2002.677326	116.245275	130445.427572
std	3588.051243	6.031581	46.609595	34659.307317
min	200.000000	1910.000000	40.000000	5000.000000
25%	1300.000000	1999.000000	75.000000	125000.000000
50%	2999.000000	2003.000000	109.000000	150000.000000
75%	6200.000000	2007.000000	143.000000	150000.000000
max	14800.000000	2016.000000	300.000000	150000.000000

	Нулевые значения	% значений	Кол-во пропусков	% пропусков
Price	0	0.0	0	0.0
VehicleType	0	0.0	0	0.0
RegistrationYear	0	0.0	0	0.0
Gearbox	0	0.0	0	0.0
Power	0	0.0	0	0.0
Model	0	0.0	0	0.0
Kilometer	0	0.0	0	0.0
FuelType	0	0.0	0	0.0
Brand	0	0.0	0	0.0
Repaired	0	0.0	0	0.0

```
Данные представлены в 10 столбцах и 263219 строках
В 0 столбцах имеются пропуски в кол-ве 0 или 0.0%
```

На данном этапе произведена загрузка данных и их подготовка:

- Для анализа данных и построения модели предоставлен датасет, содержащий информацию о технических характеристиках, комплектациях и ценах автомобилей, которые размещались на площадке сервиса «Не бит, не крашен» для продажи. Датасет состоит из 16 столбцов с данными и 354369 строк.
- Пропуски данных были в столбцах `VehicleType`, `Gearbox`, `Model`, `FuelType`, `Repaired`:
  - данные с пропусками в столбце `Model` были удалены;
  - пропуски данных в столбцах `Gearbox` и `FuelType` заполнены ниболее часто встречающимся значением для пары `Brand` - `Model`;
  - пропуски данных в столбцах `VehicleType' заменены на значение unknown`;
  - пропуски в столбце `Repaired` заменены на `no`.
- Построение диаграмм размаха позволило определить аномальные значения в столбцах `Price` `Power` и избавиться от них;
- Так же обработаны аномалии в `RegistrationYear`
- Финальным этапом предобработки данных стало удаление ненужных для обучения моделей признаков, а именно - `DateCrawled`, `RegistrationMonth`, `DateCreated`, `NumberOfPictures`, `PostalCode`, `LastSeen`.

В итоге получен датасет, состоящий из 10 столбцов с данными и 263219 строк.

Обучение моделей

Подготовим признаки, разделим исходные данные на обучающую и тестовую выборки в соотношении 75:25

In [20]
```
# Определим категориальные признаки
cat_features = ['VehicleType', 'Gearbox', 'Model', 'FuelType', 'Brand', 'Repaire

# Изменим тип, т.к. данные модели градиентного бустинга умеют работать с категор
data[cat_features] = data[cat_features].astype('category')

# Подготовим признаки
features = data.drop(['Price'], axis=1)
target = data['Price']

# Разделим данные
(features_train, features_test,
     target_train, target_test) = train_test_split(features, target,
                                                   test_size=0.25,
                                                   random_state=12345)
# Скопируем признаки для кодировки
features_train_ohe = features_train.copy()
features_test_ohe = features_test.copy()

print("Размерность тренеровочных данных", features_train.shape)
print("Размерность тестовых данных", features_test.shape)
```

```
Размерность тренеровочных данных (197414, 9)
Размерность тестовых данных (65805, 9)
```

В данных содержатся категориальные признаки, закодируем их при помощи OrdinalEncoder

In [21]
```
# Кодировка OE
encoder = OrdinalEncoder(handle_unknown='use_encoded_value', unknown_value=10050

encoder.fit(features_train[cat_features])

features_train_ohe[cat_features] = pd.DataFrame(encoder.transform(features_train
                                                columns=features_train[cat_featu
                                                index=features_train.index)
features_test_ohe[cat_features] = pd.DataFrame(encoder.transform(features_test[c
                                                columns=features_test[cat_featur
                                                index=features_test.index)
```

Проведем обучение трех моделей: `RandomForestRegressor`, `LGBMRegressor`, `CatBoostRegressor`

Модель на основе Случайного леса

In [22]
```
%%time
model_rfr = RandomForestRegressor(random_state=12345)

param_grid_rfr = {
      'n_estimators': range(10, 210, 50),
      'max_depth' : [None] + [i for i in range(2, 11)]
}

# Обучение
cv_rfr = GridSearchCV(estimator=model_rfr,
                      param_grid=param_grid_rfr,
                      cv=3,
                      n_jobs=-1,
```

```
                       scoring='neg_root_mean_squared_error',
                       verbose=10
                      )
cv_rfr.fit(features_train_ohe, target_train)

cv_rfr_best_params = cv_rfr.best_params_
cv_rfr_best_score = round(-cv_rfr.best_score_, 6)

cv_rfr_results = ['RandomForest',
                  cv_rfr_best_score,
                  round(cv_rfr.cv_results_['mean_fit_time'][cv_rfr.best_index_],
                  round(cv_rfr.cv_results_['mean_score_time'][cv_rfr.best_index_

print("best params", cv_rfr_best_params, "score", cv_rfr_best_score)
```

```
Fitting 3 folds for each of 40 candidates, totalling 120 fits
best params {'max_depth': None, 'n_estimators': 160} score 1329.22409
CPU times: total: 1min
Wall time: 6min 10s
```

Модель LightGBM для градиентного бустинга

In [23]:

```
%%time

model_lgb = LGBMRegressor()

param_grid_lgb = {
    'max_depth': [25, 50],
    'learning_rate' : [0.01, 0.03],
    'n_estimators': range(10, 800, 50),
}

cv_lgb = GridSearchCV(estimator=model_lgb,
                      param_grid=param_grid_lgb,
                      cv=3,
                      n_jobs=-1,
                      scoring='neg_root_mean_squared_error',
                      verbose=10
                     )
cv_lgb.fit(features_train, target_train)

cv_lgb_best_params = cv_lgb.best_params_
cv_lgb_best_score = round(-cv_lgb.best_score_, 6)

cv_lgb_results = ['LightGBM',
                  cv_lgb_best_score,
                  round(cv_lgb.cv_results_['mean_fit_time'][cv_lgb.best_index_],
                  round(cv_lgb.cv_results_['mean_score_time'][cv_lgb.best_index_

print("best params", cv_lgb_best_params, "score", cv_lgb_best_score)
```

```
Fitting 3 folds for each of 64 candidates, totalling 192 fits
best params {'learning_rate': 0.03, 'max_depth': 25, 'n_estimators': 760} score 1
287.548695
CPU times: total: 16.5 s
Wall time: 3min 24s
```

Модель CatBoost для градиентного бустинга

In [24]:
```
%%time
model_cb = CatBoostRegressor(random_state=12345)

param_grid_cb = {
    'depth' : range(1, 12, 2),
    'iterations': range(10, 300, 50),
}

cv_cb = GridSearchCV(estimator=model_cb,
                     param_grid=param_grid_cb,
                     cv=3,
                     n_jobs=-1,
                     scoring='neg_root_mean_squared_error',
                     verbose=10
                    )
cv_cb.fit(features_train, target_train, cat_features=cat_features, verbose=30)

cv_cb_best_params = cv_cb.best_params_
cv_cb_best_score = round(-cv_cb.best_score_, 6)

cv_cb_results = ['CatBoost',
                 cv_cb_best_score,
                 round(cv_cb.cv_results_['mean_fit_time'][cv_cb.best_index_], 6
                 round(cv_cb.cv_results_['mean_score_time'][cv_cb.best_index_],

print("best params", cv_cb_best_params, "score", cv_cb_best_score)
```

```
Fitting 3 folds for each of 36 candidates, totalling 108 fits
Learning rate set to 0.282147
0:      learn: 2883.6270834     total: 306ms    remaining: 1m 19s
30:     learn: 1306.4131369     total: 4.25s    remaining: 31.4s
60:     learn: 1240.0901950     total: 8.12s    remaining: 26.5s
90:     learn: 1195.1667524     total: 12.2s    remaining: 22.7s
120:    learn: 1175.9327643     total: 16.3s    remaining: 18.7s
150:    learn: 1155.2139576     total: 20.1s    remaining: 14.5s
180:    learn: 1139.6349828     total: 24s      remaining: 10.5s
210:    learn: 1123.3033525     total: 28.4s    remaining: 6.61s
240:    learn: 1110.4913573     total: 32.8s    remaining: 2.59s
259:    learn: 1101.7001028     total: 35.7s    remaining: 0us
best params {'depth': 11, 'iterations': 260} score 1277.551066
CPU times: total: 2min 39s
Wall time: 7min 8s
```

Анализ моделей

In [25]:
```
# функция для анализа моделей
def model_analysis (features_train, target_train, features_test, target_test, mo
    start = time.time()
    model.fit(features_train, target_train)
    end = time.time()
    fit_time = end - start

    start = time.time()
    model_pred = model.predict(features_test)
    end = time.time()
    pred_time = end - start

    rmse = round(mean_squared_error(target_test, model_pred, squared = False), 5
```

```
    return [model_name, rmse, fit_time, pred_time]
```

Проведем анализ моделей на:

- качество предсказания;
- время обучения модели;
- время предсказания модели.

Сведем полученные в ходе обучения и кросвалидации моделей данные в таблицу

In [29]:
```
model_analytics = pd.DataFrame([cv_rfr_results, cv_lgb_results, cv_cb_results],
                               columns =['Модель', 'Качество предсказания (RMSE)',
                                         'Время обучения модели, сек.',
                                         'Время предсказания модели, сек'])
model_analytics
```

Out[29]:

	Модель	Качество предсказания (RMSE)	Время обучения модели, сек.	Время предсказания модели, сек
0	RandomForest	1329.224090	55.981020	5.432731
1	LightGBM	1287.548695	5.706747	4.333320
2	CatBoost	1277.551066	95.597500	0.165333

Исследование проводилось для трех моделей: `RandomForestRegressor`, `LGBMRegressor`, `CatBoostRegressor`.
В результате при помощи `GridSearchCV` были подобраны оптимальные параметры, проведено обучение моделей а так же проанализирована скорость работы и качество моделей.
Все модели удовлетворяют заданному условию - Значение метрики RMSE меньше 2500, однако `LGBMRegressor` явлеется безусловным лидером по времени обучения (хотя и проигывает CatBoostRegressor по предсказаниям), при довольно высоком качестве модели.

Опираясь на требования заказчика, для дальнейшей работы рекомендуем применять модель на основе `LGBMRegressor`.

Тестирование лучшей модели

Проведем финальное тестирование модели

In [30]:
```
model_lgb = LGBMRegressor(**cv_lgb_best_params)
model = model_analysis(features_train, target_train, features_test, target_test,

print('Модель:', model[0],
      '\nКачество предсказания (RMSE):', model[1],
      '\nВремя обучения модели:', model[2], ' сек.',
      '\nВремя предсказания модели:', model[3], ' сек.',
      )
```

```
Модель: LightGBM
Качество предсказания (RMSE): 1276.52472
Время обучения модели: 2.973996877670288  сек.
Время предсказания модели: 0.8306150436401367  сек.
```

Полученная модель полностью соответствует требованиям заказчика. Цель достигнута